

Estimacion del consumo energetico a partir de variables climaticas HDD y CDD

Trabajo Practico Grupal – Laboratorio de Metodos Cuantitativos Aplicados a la Gestion

1er cuatrimestre 2026

Integrantes: Didier Detchemendy, Santiago Drelewicz, y Yanina Colangelo.

Repositorio: <https://github.com/SantiagoEzequielDrelewicz/TP-LMC>

Resumen

El trabajo analiza si el consumo energetico mensual puede explicarse y estimarse a partir de variables climaticas. Para ello se integraron datos de consumo de clientes T1, registros horarios de temperatura y una serie de demanda diaria. Se construyeron indicadores mensuales de Heating Degree Days (HDD) y Cooling Degree Days (CDD), se evaluaron tres modelos de regresion y se comparo el modelo seleccionado contra el metodo de estimacion utilizado por la empresa. El mejor ajuste sobre 2025 fue una regresion lineal multiple con HDD y CDD separados, con $R^2 = 0,8572$. Sin embargo, al validar enero-abril de 2026, el modelo de la empresa obtuvo menor error promedio absoluto porcentual que el modelo puramente termico.

1. Introduccion

El consumo electrico residencial presenta una relacion directa con las condiciones climaticas: temperaturas alejadas de un umbral de confort suelen aumentar el uso de calefaccion o refrigeracion. En este contexto, la pregunta principal del analisis es: *¿en que medida los indicadores termicos HDD y CDD permiten explicar el consumo mensual y estimar consumos futuros para clientes T1?*

Responder esta pregunta es relevante porque una estimacion precisa del consumo permite planificar demanda, evaluar desvios y comparar modelos operativos. El analisis se concentro en clientes de tarifa T1 y en consumos de 2025 para ajustar los modelos. Luego se contrastaron predicciones de enero a abril de 2026 contra el consumo total final observado y contra una estimacion basada en factor estacional.

2. Datos y metodologia

Se utilizaron tres fuentes principales: datasets de consumo historico 2025, temperaturas horarias de 2025 y 2026, y una tabla de demanda diaria consolidada. Los cuatro archivos de consumo 2025 se unificaron en un unico DataFrame de 711.829 filas y 26 columnas. La base presentaba 768.543 valores nulos, equivalentes al 4,15 % de las celdas. La mayor parte correspondia a FECHA BAJA, con 707.614 nulos, lo que resultaba esperable porque la mayoria de los clientes seguia activa.

Las principales transformaciones fueron:

- Se excluyeron clientes con fecha de baja para trabajar sobre clientes activos.
- Se convirtieron columnas numericas almacenadas como texto con coma decimal, como PROMEDIO CONSUMO, FACTOR ESTACIONAL y CONSUMO TOTAL FINAL.

- Se transformo REFERENCIA al mes correspondiente, dado que todos los registros de entrenamiento pertenecian a 2025.
- Para evitar duplicacion mensual por cliente, se conservo la ultima lectura de cada combinacion cliente-mes.
- Se agregaron consumos por mes y se expresaron en GWh para estabilizar la escala del ajuste.

Para representar el efecto climatico se fijo una temperatura de confort $T_c = 20^\circ C$. A partir de temperaturas horarias se calcularon desvios positivos respecto de ese umbral:

$$HDD(t) = \text{máx}(T_c - T(t), 0), \quad (1)$$

$$CDD(t) = \text{máx}(T(t) - T_c, 0). \quad (2)$$

Luego se promediaron los valores horarios a nivel diario y mensual. A partir de esos indicadores se estimó el modelo seleccionado (Modelo 1) mediante mínimos cuadrados ordinarios:


$$\text{Modelo seleccionado (Modelo 1): } \hat{C}(t) = B + \beta_H HDD(t) + \beta_C CDD(t). \quad (3)$$

Se consideraron alternativas más simples (p. ej. suma HDD+CDD) y una transformación estacional, pero dichas variantes no mejoraron el ajuste empírico sobre 2025 (ver párrafo comparativo en la subsección de selección).

3. Resultados

3.1. Comportamiento termico y consumo 2025

Los indicadores climáticos presentan una marcada estacionalidad; la evolución anual de HDD y CDD y su correlación con el consumo total final mensual se visualizan en la figura 1. El panel (a) (fig. 1a) muestra la evolución estacional de HDD y CDD, mientras que el panel (b) (fig. 1b) relaciona dichos indicadores con el consumo mensual, corroborando la correlación estacional entre variables térmicas y demanda. En 2025 los máximos de consumo se concentraron en junio–agosto, con un pico de 30,65 GWh en julio.



(a) Evolución mensual de HDD y CDD (2025).

(b) Consumo total final vs. indicadores térmicos (2025).

Figura 1: Comportamiento climático y su relación con el consumo en 2025.




Figura 2: Sensibilidad del consumo agregado respecto de HDD y CDD.


La sensibilidad estimada del consumo agregado ante variaciones de HDD y CDD (fig. 2) indica la contribución relativa de cada indicador al consumo mensual agregado; los coeficientes estimados muestran magnitud comparable entre efectos de frío y calor, aunque su interpretación predictiva requiere validación fuera de muestra.

3.2. Selección del modelo

El Modelo 1 obtuvo el mayor coeficiente de determinación. La estimación resultante fue:

$$\hat{C}(t) = 15,3351 + 1,5264 HDD(t) + 1,7062 CDD(t). \quad (4)$$

El ajuste sobre 2025 alcanzó $R^2 = 0,8572$ (R^2 ajustado = 0,825). Los coeficientes son positivos y estadísticamente significativos (HDD: $p = 0,001$; CDD: $p < 0,001$). La concordancia temporal y la correspondencia puntual entre reales y predichos se presentan en la figura 3 (paneles a y b; ver además 3a y 3b). El panel (b) complementa la evaluación al mostrar la dispersión puntual entre reales y predichos, lo que aporta información sobre la heterogeneidad de errores y la presencia relativa de desviaciones puntuales. En conjunto, estos elementos indican que, en la muestra 2025, los desvíos térmicos respecto de T_c contribuyen de forma relevante al consumo agregado.



(a) Serie temporal: consumo real y predicho (2025). (b) Diagrama de dispersión valores reales vs predichos (2025).

Figura 3: Evaluación del ajuste del Modelo 1: (a) serie temporal de reales y predichos; (b) correspondencia puntual entre reales y predichos.

3.3. Validacion con datos 2026

La simplificacion del Modelo 2 perdio solo 0,0181 puntos de R^2 respecto del Modelo 1, por lo que conserva buena parte de la informacion climatica con menor complejidad. El Modelo 3, aunque incorporo una transformacion estacional explicita, no mejoro el ajuste y quedo por debajo de los otros dos modelos.

Con las temperaturas observadas entre enero y abril de 2026, el Modelo 1 estimó un consumo total de 89,41 GWh (promedio mensual 22,35 GWh). La validación comparó dichas predicciones con el consumo real y la estimación operativa de la empresa (figura 5). En términos agregados, el MAPE de la empresa fue 4,91 % frente a 8,51 % del Modelo 1; en RMSE la empresa obtuvo 1 GWh y el modelo térmico 2 GWh. Estos indicadores cuantitativos respaldan la conclusión de que el modelo térmico, pese a un buen ajuste in-sample, ofrece menor precisión predictiva sobre el periodo de validación.

Las distribuciones de error mensual entre predicción y real se muestran en la figura 4 (paneles a y b; ver además 4a y 4b). El MAPE de la estimación operativa fue 4,91 %, frente a 8,51 % del Modelo 1; en RMSE la estimación operativa alcanzó 1 GWh y el modelo térmico 2 GWh. En consecuencia, el ajuste in-sample del Modelo 1 no se tradujo en mejor precisión predictiva sobre enero–abril de 2026; esto sugiere que, si bien HDD y CDD capturan una fracción importante de la variabilidad in-sample, resultan insuficientes por sí solos para reproducir la dinámica predictiva observada en 2026.




Figura 4: Errores porcentuales de predicción en función de los indicadores térmicos (enero-abril 2026).




Figura 5: Comparación de estimaciones y consumo real para enero-abril 2026.

¿En qué medida HDD y CDD permiten explicar y predecir el consumo energético?

HDD y CDD explican una proporción substancial de la variabilidad mensual sobre la muestra de ajuste (2025): el modelo lineal múltiple con ambos indicadores alcanza $R^2 = 0,8572$, lo que implica que más del 85 % de la varianza mensual queda explicada in-sample. Sin embargo, la validación sobre enero–abril de 2026 muestra que la capacidad predictiva es limitada: el MAPE agregado de la estimación operativa fue 4,91 % frente a 8,51 % del modelo térmico, y el RMSE operativo fue 1 GWh frente a 2 GWh. Por tanto, HDD y CDD permiten explicar de manera robusta el comportamiento agregado dentro de la muestra, pero su poder predictivo sobre el periodo de validación es insuficiente cuando se usan de forma exclusiva. Estas observaciones aconsejan integrar variables calendario, demanda y rezagos para mejorar la precisión predictiva.

4. Conclusiones

Síntesis: HDD y CDD capturan una fracción sustantiva de la variabilidad mensual agregada —el modelo térmico alcanzó $R^2 = 0,8572$ sobre 2025— pero no aseguran precisión predictiva fuera de la muestra: en enero–abril de 2026 el MAPE del modelo térmico (8,51 %) fue superior al de la estimación operativa (4,91 %).

Implicaciones: las variables térmicas son insumo relevante para estimación agregada, pero su uso exclusivo limita la exactitud predictiva. Para aplicaciones operativas es recomendable complementar HDD/CDD con variables calendario, indicadores de demanda y rezagos de consumo, o bien incorporar modelos híbridos que permitan capturar efectos no térmicos.

Limitaciones: el análisis se concentra en agregados mensuales y en clientes T1; además, no se incluyeron variables socioeconómicas ni eventos extraordinarios que podrían explicar desviaciones puntuales. La periodización de validación (enero–abril 2026) es breve: extender la ventana mejorará la robustez de las conclusiones.

Líneas futuras: 1) probar modelos híbridos (térmicos + calendario + demanda); 2) validar por subconjuntos de clientes; 3) aumentar horizonte de validación y considerar modelos con estructura de errores heterocedásticos o efectos no lineales.

5. Reflexion metodologica

El desarrollo combinó: (i) procesamiento y modelado reproducible en Python (el notebook contiene las transformaciones y cálculos), (ii) verificación humana de resultados intermedios y (iii) asistencia de IA para sintetizar, revisar coherencia y mejorar redacción. El equipo validó las salidas del notebook contra tablas intermedias y figuras antes de incluirlas en el informe.

Ventajas del uso de IA: aceleró la revisión de estilo, detectó incoherencias y ayudó a compactar la exposición técnica. Limitaciones: la IA no sustituye la verificación numérica; todas las afirmaciones cuantitativas se contrastaron con el notebook y fueron aprobadas manualmente. Recomendación metodológica: usar IA como apoyo de redacción y revisión, manteniendo siempre la cadena de verificación reproducible (código → tablas intermedias → figuras → texto).